Open in Colab

Gradientenabstiegsverfahren als numerisches Optimierungsverfahren

Dieses Notebook behandelt den Gradientenabstieg so, wie er in der numerischen Mathematik ueblicherweise eingefuehrt wird: als iteratives Verfahren zur unrestringierten Minimierung einer differenzierbaren Funktion $f: \mathbb{R}^n \to \mathbb{R}$.

Testfunktion ist die **Rosenbrock-Funktion** (auch "Bananenfunktion" genannt), ein Standardbeispiel in der nichtlinearen Optimierung:

$$f(x, y) = (a - x)^2 + b \cdot (y - x^2)^2, \qquad \text{ueblich } a=1,\ b=100$$

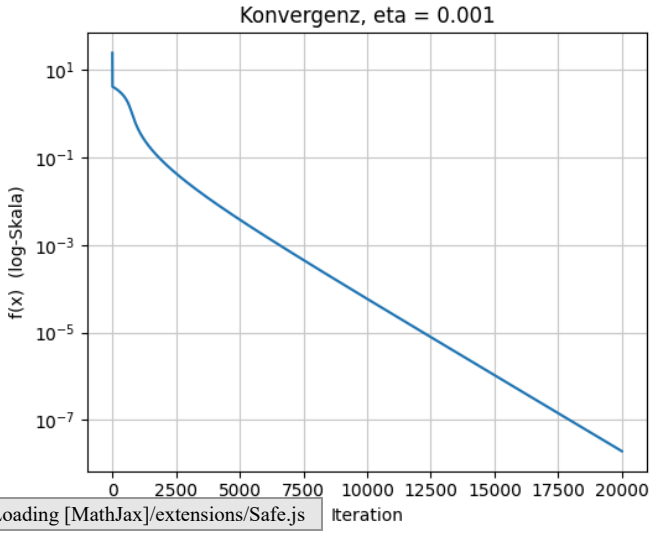
Sie hat ein einziges globales Minimum bei $(a, a^2) = (1, 1)$, liegt aber in einem sehr flachen, gekruemmten Tal -- ein gutes Beispiel dafuer, warum reiner Gradientenabstieg dort nur langsam konvergiert und wie stark die Wahl der Schrittweite (Lernrate) η das Ergebnis beeinflusst.

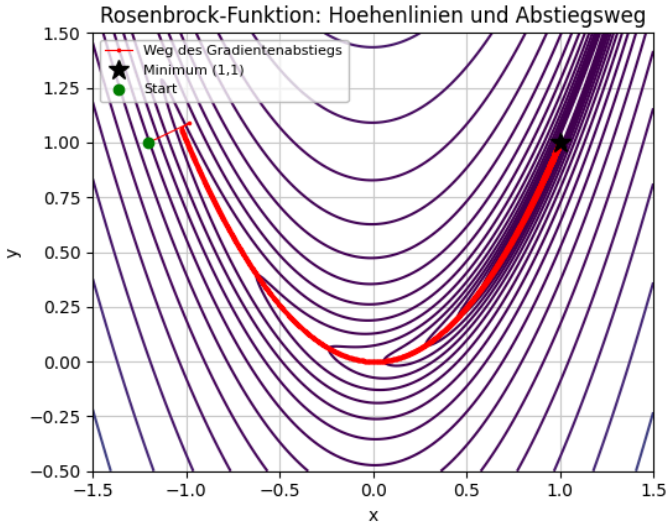
Verhalten bei unterschiedlichen Lernraten

```
Gradientenabstieg auf der Rosenbrock-Funktion
Startpunkt: [-1.2  1. ], gesuchtes Minimum: (1, 1)

eta = 0.0001   -> 20000 Schritte, x = (0.7197, 0.5166), f(x) = 0.078767
eta = 0.001    -> 20000 Schritte, x = (0.9999, 0.9997), f(x) = 0.000000
eta = 0.002    -> 20000 Schritte, x = (1.0003, 0.9981), f(x) = 0.000692
```

Konvergenzverlauf und Weg im Hoehenlinienbild





Loading [MathJax]/extensions/Safe.js

Zum Vergleich: Das Newton-Verfahren nutzt zusaetzlich die Kruemmung (Hesse-Matrix) und konvergiert auf dieser Funktion in wenigen Schritten statt Tausenden -- Thema eines späteren Abschnitts.

Loading [MathJax]/extensions/Safe.js